

FORD

Sprint 03 - Inteligência Artificial & Machine Learning

Classificação Preditiva de Perfil Comportamental de Clientes

Resumo e Comparação de Modelos

Integrante	RM
Arthur Bobadilla Franchi	555056
Luan Orlandelli Ramos	554747
Jorge Luiz	554418

1. Compreensão do Problema

Desafio de negócio: a Ford enfrenta uma assimetria de informação no ponto de venda no momento da compra, a concessionária não sabe se o cliente futuramente será fiel à rede oficial de manutenção ou irá migrar para oficinas externas. Isso impede ações de retenção proativas e personalizadas.

Objetivo da solução: prever, já no momento da compra do veículo, o perfil comportamental futuro do cliente (Fiel, Econômico, Esquecido ou Abandono), permitindo que a concessionária ative o protocolo de retenção correto desde o primeiro contato sem esperar 24 meses para observar o comportamento real.

Caracterização do problema: o projeto foi estruturado em duas etapas complementares, evitando data leakage:

- Etapa 1 - Aprendizado não supervisionado (Clustering): K-Means (k=4) sobre 12 variáveis comportamentais pós-venda da Base 1 (histórico completo), para descobrir os perfis reais de comportamento.
- Etapa 2 - Aprendizado supervisionado (Classificação multiclasse): os rótulos dos clusters viram variável-alvo; um classificador é treinado usando exclusivamente as 23 variáveis disponíveis no momento da compra (Base 2), simulando o cenário real de operação da concessionária.

Dados utilizados: 500.000 registros de clientes Ford, com 37 variáveis na Base 1 (histórico, taxa de nulos 0,4%) e 24 variáveis na Base 2 (momento da compra, taxa de nulos 1,2%).

2. Preparação dos Dados

Problema	Decisão	Justificativa
Valores nulos (< 2,5% por coluna)	Imputação por mediana	Robusta a outliers; taxa baixa não distorce a distribuição
330 registros: compra_a_vista=0 e prazo=0	Corrigido para compra_a_vista=1	Inconsistência lógica: sem prazo de financiamento = pagamento à vista
Outliers em renda, distância e gasto	Winsorização 1%–99%	Preserva a distribuição real, elimina extremos espúrios
Variáveis categóricas (5 colunas)	One-Hot Encoding	Compatibilidade com algoritmos baseados em distância/gradiente
Escalas heterogêneas	StandardScaler	K-Means e Logistic Regression são sensíveis à magnitude das variáveis

Divisão treino/teste: split estratificado 80/20 (400k treino / 100k teste), preservando a proporção de cada classe. As features de clustering (Etapa 1) e de classificação (Etapa 2) foram mantidas estritamente separadas para eliminar data leakage.

3. Segmentação Comportamental - Etapa 1 (K-Means)

Definição de k: k=4, validado pelo método do cotovelo, Silhouette Score ($\approx 0,32$) e alinhamento com as 4 hipóteses de perfil levantadas pelo time de negócio. O modelo concordou em $\geq 91\%$ dos casos com o ground truth (perfil_latente).

Segmento	% Base	Revisões/24m	Share Rede	Gasto (24m)	Satisfação	Churn
Fiel	30,1%	3,95	93,1%	R\$ 4.266	9,4/10	2,2%
Econômico	25,4%	2,73	57,4%	R\$ 1.429	7,1/10	7,1%
Esquecido	23,8%	1,13	26,2%	R\$ 315	3,9/10	25,3%
Abandono	20,7%	1,23	17,4%	R\$ 213	4,8/10	27,5%

4. Desenvolvimento dos Modelos - Etapa 2 (Classificação)

Foram avaliados quatro algoritmos de complexidade e interpretabilidade crescentes/decrescentes, todos treinados exclusivamente com variáveis do momento da compra:

Modelo	Tipo	Interpretabilidade	Papel na comparação
Logistic Regression	Linear	Alta	Baseline sólido — modelo eleito
Decision Tree	Não-linear	Muito alta	Baseline de referência
Random Forest	Ensemble	Média	Melhor generalização, feature importance
MLP (Rede Neural)	Não-linear / deep	Baixa	Teste de ganho por interações não-lineares

Ajuste de hiperparâmetros: aplicado GridSearchCV (cv=3, scoring=f1_macro) sobre a Logistic Regression, variando $C \in \{0,01; 0,1; 1; 10; 100\}$ e $\text{penalty} \in \{l1, l2\}$. A configuração default (C=1,0, l2) já operava próxima do ótimo, confirmando a escolha inicial com evidência estatística.

Validação cruzada: cross_val_score com 5 folds estratificados confirmou baixo desvio-padrão entre folds, indicando estabilidade do modelo e ausência de overfitting a um split específico.

5. Avaliação e Comparação de Resultados

5.1 Comparação geral entre algoritmos

Modelo	Acurácia	F1 Macro	F1 Weighted	Decisão
Logistic Regression	79,0%	0,766	0,786	Eleito
Random Forest	78,8%	0,768	0,785	Comparativo
MLP (Rede Neural)	≈78%*	≈0,74*	≈0,78*	Comparativo
Decision Tree	74,3%	0,741	0,742	Baseline

* Resultados do MLP variam levemente entre execuções (inicialização aleatória de pesos); mesmo no melhor caso, não supera a Logistic Regression, reforçando que a relação entre as variáveis de compra e o perfil comportamental é predominantemente linear.

5.2 Métricas por classe — Logistic Regression (modelo eleito)

Segmento	Precisão	Recall	F1-Score	Interpretação
Fiel	0,97	0,98	0,97	Perfil mais discriminável — acerto quase perfeito
Econômico	0,80	0,86	0,83	Boa precisão; alguma confusão com Esquecido
Esquecido	0,69	0,72	0,71	Erros predominantemente trocados com Abandono
Abandono	0,61	0,52	0,56	Classe mais difícil — perfil de compra similar ao Esquecido

Análise da matriz de confusão: a confusão entre Abandono e Esquecido é estrutural ambos compartilham baixo planejamento de manutenção no ato da compra. Do ponto de vista de negócio, esse erro é aceitável: classificar um Esquecido como Abandono (ou vice-versa) ainda aciona o protocolo correto de intervenção de alto risco.

5.3 Principais drivers preditivos (Top 5)

Feature	Importância	Interpretação de negócio
organizacao_proxy	0,25	Comportamento organizado no ato da compra prediz fortemente o perfil Fiel
sensibilidade_preco_inicial	0,25	Alta sensibilidade inicial discrimina Econômico e Abandono
tempo_decisao_dias	0,08	Decisão rápida correlaciona com Abandono; decisão lenta com Econômico
distancia_concessionaria_km	0,08	Maior distância eleva a probabilidade de evasão futura
score_credito	0,05	Score mais alto associado ao perfil Fiel

6. Conclusão

6.1 Modelo selecionado e justificativa

- Melhor acurácia geral (79,0%) e melhor F1 Weighted (0,786) entre os quatro algoritmos testados;
- Interpretação nativa dos coeficientes por classe, permitindo auditoria e explicação ao time de negócio;
- Inferência em tempo real, sem custo computacional relevante — ideal para integração no CRM da concessionária;
- Estabilidade confirmada por validação cruzada (baixo desvio-padrão entre folds);
- O ajuste de hiperparâmetros (GridSearchCV) e a comparação com uma rede neural (MLP) confirmam, com evidência empírica, que a configuração já opera próxima do limite de desempenho alcançável com os dados disponíveis no momento da compra.

6.2 Principais resultados

- 79% de acurácia e F1 macro de 0,77 prevendo o segmento comportamental usando apenas dados do momento da compra — zero data leakage;
- Classe Fiel com F1 = 0,97 (quase perfeita); classes de risco Esquecido/Abandono com F1 entre 0,56–0,71, mas confundidas majoritariamente entre si — erro aceitável, pois ambas acionam protocolos de alto risco;
- Abandono e Esquecido juntos representam 44,5% da base e concentram as maiores taxas de churn (27,5% e 25,3%) — são o foco prioritário de ação comercial.

6.3 Forma de deploy proposta

- Serialização do modelo (Logistic Regression + StandardScaler) via joblib/pickle;
- Empacotamento como microsserviço REST (ex.: FastAPI), com endpoint único POST /predict-segmento;
- Integração direta no CRM da concessionária: no fechamento da venda, o sistema chama o endpoint e grava o segmento previsto, disparando o protocolo de retenção correspondente;
- Monitoramento contínuo de data drift e concept drift, comparando periodicamente a previsão com o comportamento real observado após 24 meses;
- Retreinamento periódico (trimestral/semestral) incorporando novos clientes que já completaram o ciclo de relacionamento.

6.4 Melhorias e trabalhos futuros

- Calibração de probabilidades (CalibratedClassifierCV) para priorização mais confiável de campanhas;
- Engenharia de features adicionais (histórico multimarca, sazonalidade, geolocalização mais granular);
- Classificador binário dedicado à fronteira Esquecido/Abandono, reduzindo a confusão entre essas classes;
- Ensembles/stacking combinando Logistic Regression e Random Forest;
- Coleta de sinais comportamentais de curto prazo (4–8 semanas pós-compra) para uma re-classificação antecipada;
- Teste A/B em campo para validar o ROI real das ações de retenção direcionadas pelo modelo.